

Министерство науки и высшего образования Российской Федерации
федеральное государственное бюджетное образовательное учреждение
высшего образования

«Российский экономический университет имени Г.В. Плеханова»

Высшая школа кибертехнологий, математики и статистики

Кафедра математических методов в экономике

Направление 38.03.01 «Экономика»

Профиль «Аналитическая экономика и эконометрика»

Курсовая работа

по дисциплине “Основы машинного обучения в экономике и финансах”
на тему “Построение модели машинного обучения для прогнозирования ВВП”

Выполнил обучающийся
группы 15.27Д-Э01/236
очной формы обучения

Нгуен Динь Чиеу

Научный руководитель:
к.э.н., доцент, доцент кафедры
Сукиасян Ани Гагиковна

(подпись)

Москва

2026

СОДЕРЖАНИЕ

СОДЕРЖАНИЕ.....	2
Введение.....	3
Глава 1: Сбор и интеллектуальный анализ данных.....	6
1.1. Статистический анализ: Среднее значение, медиана, стандартное отклонение, коэффициент вариации, минимальное и максимальное значения.....	8
1.2. Визуализация всех признаков с помощью гистограммы и анализ корреляций.....	11
Глава 2: Разделение набора данных и обучение модели машинного обучения.....	15
2.1. Разделение набора данных на обучающий и тестовый наборы.....	15
2.2. Обучение модели на обучающих данных.....	16
2.3. Оценка качества модели на тестовых данных.....	17
Глава 3: Улучшение модели с помощью предобработки данных.....	22
3.1. Предобработка данных.....	22
3.2. Обучение и оценка модели.....	22
3.3. Сравнительный анализ результатов до и после предобработки.....	25
Заключение.....	28
Список литературы.....	31
Приложение.....	33

Введение

Актуальность данного исследования обусловлена необходимостью выявления ключевых факторов, определяющих валовой внутренний продукт (ВВП), который является главным индикатором экономического роста и уровня развития страны. В условиях глобализации и усиления экономической взаимозависимости между странами анализ вклада таких секторов, как строительство, обрабатывающая промышленность, транспорт, торговля, конечное потребление, а также демографических показателей, приобретает особую значимость. Кроме того, актуальность работы связана с необходимостью выбора адекватных методов предобработки данных (логарифмирование, масштабирование, борьба с мультиколлинеарностью) и сравнения классических эконометрических подходов с современными методами машинного обучения для повышения точности прогнозирования ВВП.

Целью данной работы является машинное моделирование влияния десяти ключевых макроэкономических показателей на ВВП на основе панельных данных за 1975–2020 гг.

Для достижения поставленной цели необходимо решить следующие задачи:

- Провести описательный статистический анализ всех переменных; Оценить характер распределения каждой переменной и при необходимости выполнить логарифмическое преобразование для приближения к нормальному распределению.
- Построить матрицу корреляции и выявить мультиколлинеарность между факторами.

- Сравнить эффективность моделей машинного обучения и выбрать одну модель для прогнозирования
- Оценка качества модели на тестовой выборке с использованием кросс-валидации.
- Интерпретировать полученные результаты и дать рекомендации по выбору оптимального подхода.

Объектом исследования выступают макроэкономические показатели 10 показателей (строительство, обрабатывающая промышленность, добыча и коммунальные услуги, транспорт и связь, другие виды деятельности, экспорт, импорт, конечное потребление, валовой национальный доход, население) в разрезе стран и лет.

Предметом исследования являются количественные закономерности влияния указанных факторов на ВВП, а также методы предобработки данных и построения прогнозных моделей.

В работе используются следующие **методы исследования**:

Статистические методы (расчёт средних, стандартных отклонений, квантилей, коэффициентов вариации, построение гистограмм и матрицы корреляции).

Методы предобработки данных (логарифмирование, масштабирование, удаление выбросов).

Эконометрические методы (множественная линейная регрессия, тестирование мультиколлинеарности, анализ остатков).

Программная реализация на языке Python с использованием библиотек pandas, numpy, scikit-learn, matplotlib, seaborn.

Глава 1: Сбор и интеллектуальный анализ данных.

Основная информация о собранном наборе данных представлена далее. Данные исследования для каждой страны охватывают 52 года (с 1970 по 2021 год) и представлены в виде ежегодных наблюдений, страны расположены в алфавитном порядке. Целевая переменная — ВВП (GDP), а 10 признаков включают: строительство (construction), обрабатывающую промышленность (manufacturing), горнодобывающую промышленность, производство и коммунальные услуги (mining manufacturing utilities), транспорт, хранение и связь (transport storage and communication), другие виды деятельности (other activities), экспорт товаров и услуг (exports of goods and services), импорт товаров и услуг (imports of goods and services), конечные потребительские расходы (final consumption expenditure), валовой национальный доход в долларах США (gross national income (GNI) in usd) и население (population).

После обработки пропущенных значений методом интерполяции (interpolate) мы получили 10 148 наблюдений, при этом только признак population представлена в виде целых чисел, а все остальные — в виде вещественных чисел. Мы использовали панельные данные. Есть несколько причин для использования панельных данных в прикладных исследованиях:

1. Большое количество наблюдений. Если вы используете пространственные данные, то в вашем распоряжении, по всей видимости, будет менее 200 наблюдений. Ведь даже если вы включите в выборку все независимые государства-члены ООН, то их окажется меньше двухсот. А если оставить только те из них, по которым доступна достаточно полная статистическая информация, список окажется ещё короче. С другой стороны,

применив панельные данные, вы будете иметь возможность использовать гораздо больше точек. Например, получив информацию о 100 странах за 10 лет, вы сможете строить регрессии по $100 \cdot 10 = 1000$ наблюдений.

Количество доступных наблюдений зависит от того, имеете ли вы дело со сбалансированной или несбалансированной панелью. Панель называется сбалансированной, если существует наблюдение для каждого объекта и для каждого момента времени. В этом случае общее число наблюдений равно . Когда в данных есть пропуски, панель называется несбалансированной. В этом случае общее число наблюдений меньше, чем , однако все равно может оставаться достаточно большим. Если возникновение пропусков является экзогенным, то для несбалансированных панелей можно использовать те же методы оценивания, что и для сбалансированных.

2. Возможность отслеживать динамику для множества объектов. Использование панельных данных позволяет анализировать распределение тех или иных эффектов во времени. Например, постепенное изменение потребления сигарет в некоторой стране после принятия антитабачных законов в ряде её регионов.

3. Дополнительный способ устранения эндогенности. Пожалуй, самым главным мотивом для использования панельных данных является возможность получить состоятельные оценки коэффициентов при интересующих нас переменных в условиях, когда на пространственной выборке это невозможно. Такой шанс появляется за счет учета неоднородности моделируемых объектов.

1.1. Статистический анализ: Среднее значение, медиана, стандартное отклонение, коэффициент вариации, минимальное и максимальное значения.

Можно рассчитать статистические показатели для каждой страны за весь период, но для упрощения мы рассчитаем показатели по всему периоду для всех стран вместе. Это позволит получить общее представление о распределении каждого показателя.

Таблица 1: Статистический анализ исходных данных

	y	x1	x2	x3	x4
count	10148	10148	10148	10148	10148
mean	74497367629	11738378598	17908929405	5858899048	25691554204
std	2,17369E+11	34992364869	49553306406	16207689598	82464561375
min	2585174	-248499	-2581190	-6479048	1044040
25%	1330181282	102615718	167418738	85013855	331272109
50%	7111072418	824127566	1424881842	498096937	1913553779
75%	41499310048	5924874065	10204876106	3178551688	11263747345
max	3,2E+12	4,61E+11	5,96E+11	1,81E+11	1,04E+12
Коэ. Вариации	291.781086	298.102200	276.696084	276.633707	320.979263


x5	x6	x7	x8	x9	x10
10148	10148	10148	10148	10148	10148
27364654916	25963076844	54362285571	73113637030	20169198	27364654916
80378947564	74437715689	1,59475E+11	2,13862E+11	77922039	80378947564
-1669759280	1982159	2043926	3564833	4359	-1669759280
377887044	554934941	1137124668	1312278666	579323	377887044
2158413718	2635613804	5841687002	6941895103	4662172	2158413718
12543754856	12890490956	30424479161	40453646081	14541965	12543754856
8,4E+11	7,65E+11	2,26E+12	3,15E+12	1407563842	8,4E+11
293.732729	286.706064	293.356027	292.506472	386.341777	293.732729

Анализ статистических данных показывает, что все десять показателей имеют крайне высокую вариацию: коэффициенты вариации варьируются от 276% до 386%, что свидетельствует о сильной неоднородности данных и наличии значительных выбросов; средние значения по всем переменным существенно превышают медианы (например, для ВВП среднее 74,5 млрд против медианы 7,1 млрд), что указывает на правостороннюю асимметрию и концентрацию больших значений у небольшой части наблюдений; диапазоны значений простираются от отрицательных величин и миллионов до сотен миллиардов и триллионов долларов, при этом максимальные значения достигают 3,2 трлн для ВВП, 461 млрд для обрабатывающей промышленности

и 1,4 млрд для населения, а минимальные включают отрицательные показатели, например, для экспорта товаров и услуг (-1,67 млрд), что характерно для макроэкономических панельных данных по разным странам и годам, включая периоды кризисов.

1.2. Визуализация всех признаков с помощью гистограммы и анализ корреляций.

Поскольку собранный набор данных содержит более 10 000 наблюдений и характеризуется сильной правосторонней асимметрией по всем признакам, для более наглядного восприятия и анализа распределений были построены гистограммы с логарифмической шкалой. Использование логарифмического масштаба позволило сжать широкий диапазон значений и сделать структуру данных более интерпретируемой.







График 1: Гистограммы распределения признаков с логарифмической шкалой

После применения логарифмического преобразования ко всем переменным форма распределения данных значительно улучшилась по сравнению с исходным видом. Гистограммы показывают, что большинство переменных, таких как экспорт, импорт, конечные потребительские расходы, валовой национальный доход, население и ВВП, имеют распределение, близкое к нормальному (частично симметричное), диапазон изменений существенно сузился, а выбросы (outliers) были приближены к центру распределения. Это подтверждает, что логарифмическое преобразование является подходящим методом для стабилизации дисперсии и уменьшения сильной правосторонней асимметрии, присущей макроэкономическим данным.

Для остальных переменных, таких как строительство, обрабатывающая промышленность, горнодобывающая промышленность, производство и

коммунальные услуги, транспорт, хранение и связь, а также другие виды деятельности, распределение после логарифмирования также демонстрирует тенденцию к большей концентрации. Хотя всё ещё наблюдается некоторая незначительная асимметрия, в целом оно значительно улучшилось по сравнению с исходными данными.

Далее мы проанализировали корреляционную матрицу, чтобы определить, какие признаки оказывают наибольшее влияние на целевую переменную.



Корреляционная матрица показывает, что целевая переменная ВВП имеет очень тесную связь с большинством макроэкономических переменных. В частности, ВВП коррелирует практически абсолютно с валовым национальным доходом (ВНД) с коэффициентом 1,00, что полностью соответствует экономической теории, поскольку ВНД и ВВП имеют практически идентичную взаимосвязь. Кроме того, ВВП имеет очень высокие коэффициенты корреляции с транспортом, хранением и связью (0,99), конечными потребительскими расходами (0,99), другими видами деятельности (0,98), строительством (0,96) и обрабатывающей промышленностью (0,92). Это показывает, что такие отрасли экономики, как строительство, производство, транспорт, конечное потребление, играют важную роль в объяснении динамики ВВП. Экспорт и импорт также имеют довольно высокую корреляцию с ВВП — 0,87 и 0,92 соответственно, что отражает важность международной торговли для экономического роста. Примечательно, что переменная населения имеет корреляцию на среднем низком уровне (0,40) с ВВП, что показывает, что численность населения не является основным определяющим фактором валового внутреннего продукта. Одной из проблем, которую следует отметить, является то, что большинство независимых переменных имеют очень высокую корреляцию друг с другом (многие пары превышают 0,9), особенно между транспортом, хранением и связью и конечными потребительскими расходами (1,00), другими видами деятельности (0,99) и ВНД (0,99). Это свидетельствует о наличии очень серьёзной мультиколлинеарности между независимыми переменными. На основе матрицы корреляции, можно рассмотреть возможность исключения некоторых переменных для избежания мультиколлинеарности, что будет выполнено в следующей части.

Глава 2: Разделение набора данных и обучение модели машинного обучения.

Прежде всего выделили матрицу признаков X , из которой исключили переменную «country» (страны) как нечисловой, а также вектор целевой переменной y , в качестве которого выступил показатель ВВП. Таким образом, модель обучалась только на экономических, социальных и демографических факторах, без привязки к конкретной стране.

2.1. Разделение набора данных на обучающий и тестовый наборы.

Важно подчеркнуть, что мы не использовали функцию `train_test_split` с параметром `shuffle=False` в данном контексте [4]. Причина заключается в следующем: в обучающую выборку попадут лишь данные по первым 80% стран из этого упорядоченного набора. Соответственно, все оставшиеся 20% стран, которые могут обладать принципиально иными экономическими характеристиками, модель просто не увидит на этапе валидации.

Это приведёт к нерепрезентативной оценке качества модели: метрики на тестовой выборке окажутся завышенными или заниженными в зависимости от того, насколько структура «невидимых» стран отличается от структуры «увиденных». Иными словами, модель будет проверяться на заведомо незнакомом распределении данных, что нарушает фундаментальное требование случайности при разбиении выборки [7].

Вместо этого мы применили временное разделение: в обучающую выборку войдут наблюдения по всем странам за период с 1970 по 2011 год включительно, а в тестовую — данные за 2012–2021 годы. Этот подход

позволяет сформулировать задачу именно как задачу прогнозирования будущих значений на основе исторической ретроспективы [2]. Код в питоне:

```
x_train = x[df['year'] <= 2011]
x_test  = x[df['year'] > 2011]
y_train = y[df['year'] <= 2011]
y_test  = y[df['year'] > 2011]
```

2.2. Обучение модели на обучающих данных.

Далее мы построили базовую модель случайного леса (Random Forest) с параметрами по умолчанию и зафиксированным `random state = 42` для воспроизводимости результатов [8].

Случайный лес (Random Forest) — это ансамблевый метод машинного обучения, предложенный Лео Брейманом в 2001 году [5]. Данный метод предназначен для решения задач классификации и регрессии и основан на построении большого числа решающих деревьев (decision trees). Каждое дерево в ансамбле строится по выборке, полученной из исходной обучающей выборки с помощью бутстрепа (bootstrap aggregating, или bagging), то есть случайной выборки с возвращением [2]. В отличие от классических алгоритмов построения деревьев решений (таких как CART), в методе случайного леса на каждом этапе расщепления вершины используется не весь набор признаков, а только фиксированное число случайно отобранных признаков [2, 5]. Кроме того, деревья строятся полностью (без усечения, pruning), то есть каждый лист дерева может содержать наблюдения только одного класса — для задач классификации. В случае регрессии оценка условного математического ожидания отклика при

данном значении вектора признаков вычисляется как среднее значение откликов в соответствующей терминальной вершине [5].

Одним из ключевых достоинств случайного леса является его устойчивость к переобучению (overfitting) даже в случае, когда количество признаков значительно превышает количество наблюдений [5]. Это свойство достигается за счёт «двойной инъекции случайности» – на этапе формирования бутстреп-выборок и на этапе случайного отбора признаков для расщепления вершин, что обеспечивает слабую коррелированность решений отдельных деревьев и, как следствие, высокую точность ансамбля [2, 5].

Для оценки качества регрессионной модели применяют такие метрики, как средняя абсолютная ошибка (MAE), коэффициент детерминации (R-квадрат) и среднеквадратическая ошибка (MSE) [9, 7].

Случайный лес — это эффективный инструмент непараметрической регрессии, позволяющий моделировать сложные нелинейные связи между признаками и целевой переменной [6, 9].

Использование ансамбля деревьев решений снижает риск переобучения по сравнению с одним деревом. Параметр `Random_state` = 42 был зафиксирован, чтобы при повторном запуске кода получались одинаковые разбиения и результаты — это упрощает сравнение между моделями [2].

2.3. Оценка качества модели на тестовых данных.

Для оценки качества модели использовались метрики: коэффициент детерминации, средняя абсолютная ошибка, среднеквадратичная ошибка и корень из средней квадратической ошибки [6]. Выбор именно этого набора

метрик обусловлен тем, что R^2 показывает, какую долю дисперсии ВВП объясняет модель — чем ближе к 1, тем лучше. MAE интерпретируется в тех же единицах, что и целевая переменная (например, в долларах ВВП), и дает представление о типичной абсолютной ошибке предсказания [8]. MSE и RMSE сильнее штрафуют за крупные ошибки, что особенно важно в задаче прогнозирования ВВП, где выбросы не должны оставаться незамеченными [2]. Совместное использование всех четырёх метрик позволяет получить всестороннюю оценку. Результаты оценки на тестовой выборке представлены ниже.

Таблица 2: Результаты оценки модели

Метрика	Значение
R^2	0.993
MAE	6138545413.71
MSE	9.177422460590682e+20
RMSE	30294260942.612

Полученные метрики на тестовой выборке демонстрируют противоречивую картину. С одной стороны, коэффициент детерминации $R^2 = 0.993$ является исключительно высоким — модель объясняет 99,3% дисперсии целевой переменной ВВП. На первый взгляд, это говорит о почти идеальном качестве прогнозирования. Однако другие метрики вызывают серьёзные сомнения в реальной практической пригодности модели. $MAE \approx 6,14$ миллиардов долларов — средняя абсолютная ошибка составляет более 6

миллиардов, что является колоссальной величиной для большинства стран. $RMSE \approx 30,3$ миллиарда долларов — корень среднеквадратичной ошибки еще выше, что указывает на наличие значительных выбросов в ошибках прогнозирования [7]. Поскольку ВВП измеряется в широком диапазоне — от миллионов до триллионов долларов, — модель может показывать хорошую относительную точность для крупных экономик, но при этом допускать неприемлемо большие ошибки в абсолютном выражении. Кроме того, столь высокий R^2 вызывает подозрение на переобучение (overfitting) модели. Случайный лес с параметрами по умолчанию (в частности, с неограниченной глубиной деревьев) склонен идеально подстраиваться под обучающие данные, теряя обобщающую способность.

Для получения более устойчивой и надежной оценки мы применили кросс-валидацию (cross-validation) с 6 блоками (cv=6) на тренировочной выборке [9]. Данный метод позволяет оценить, насколько стабильно модель работает на различных подмножествах исторических данных, и выявить возможную проблему переобучения.

```
cv = cross_val_score(model,x_train,y_train,
                      scoring='neg_mean_squared_error',cv= 6)

cv_rmse = np.sqrt(-cv)

print(f"RMSE fold: {cv_rmse}")
```

Функция `cross_val_score` при параметре `scoring = 'neg_mean_squared_error'` возвращает не обычную среднеквадратичную ошибку (MSE), а её отрицательное значение [10]. Это сделано потому, что в библиотеке `scikit-learn`

все метрики качества реализованы по принципу «чем больше, тем лучше». Для метрик ошибок (MSE, MAE, RMSE), где чем меньше значение, тем лучше, используется инверсия знака — отрицательное значение ошибки [6]. Таким образом, чем лучше модель, тем выше (ближе к нулю) будет отрицательное MSE.

Так как мы получаем отрицательные значения, для восстановления истинной величины ошибки необходимо взять полученные значения с обратным знаком (умножить на -1), а затем извлечь квадратный корень для перехода от MSE к RMSE: `cv_rmse = np.sqrt(-cv)`. В этой строке `-cv` меняет знак каждого элемента массива с отрицательного на положительный, после чего `np.sqrt()` вычисляет корень квадратный. В результате мы получаем истинные значения RMSE для каждого из шести фолдов кросс-валидации [5].

Значение `cv = 6` даёт разумный компромисс между смещением и разбросом (дисперсией): на каждой итерации примерно 5/6 данных (около 83%) идёт на обучение, а 1/6 (около 17%) — на проверку. Этого достаточно для статистически значимой оценки, и при этом модель обучается на нужном объёме данных. Разделение на шесть частей позволяет учесть разные сочетания стран с различным уровнем экономического развития [10].

Для кросс-валидации выбрана метрика RMSE — среднеквадратичная ошибка [10]. RMSE выражается в тех же единицах, что и целевая переменная, что упрощает понимание результатов. Вот результаты кросс-валидации: 1,62 млрд, 4,97 млрд, 4,97 млрд, 5,47 млрд, 6,33 млрд и 22,91 млрд долларов США.

В блоках есть большой разброс значений. Пять блоков дают стабильные результаты от 1,62 до 6,33 млрд долларов, но один блок показывает ухудшение: RMSE составляет 22,91 млрд долларов. Это почти в 14 раз хуже лучшего показателя. Стандартное отклонение, которое составляет 7,8 млрд, показывает высокую нестабильность.

Качество модели напрямую зависит от того, как устроена обучающая выборка. В шестой сегмент угодили страны с либо запредельно высоким, либо, наоборот, крайне низким ВВП. А вот два других сегмента выдали одинаковый результат — 4,97 млрд. В целом итоги кросс-валидации лишь лишний раз подтверждают: базовая настройка со стандартными параметрами надёжностью не блещет. Дальше, видимо, стоит попробовать подправить модель через предобработку данных.

Глава 3: Улучшение модели с помощью предобработки данных.

3.1. Предобработка данных.

Подготовка данных по праву считается одной из ключевых стадий в машинном обучении — именно от неё зависит, насколько качественным окажется исходный материал для построения по-настоящему эффективных моделей. Реальные данные, поступающие из разных источников, сплошь и рядом содержат ошибки, пропуски и выбросы, а это напрямую сказывается на точности и стабильности алгоритмов. Вот почему грамотная предобработка перед запуском обучения способна заметно поднять производительность модели [3, 4].

Числовые признаки пришлось стандартизировать с помощью `StandardScaler` — после этой операции среднее значение каждого признака обнулилось, а стандартное отклонение стало равно единице. Такая мера совершенно необходима, ведь исходные переменные имели разный масштаб: например, объёмы экспорта измеряются в миллиардах долларов, тогда как численность населения — в миллионах человек. Без нормализации признаки с крупными абсолютными значениями просто подавят те переменные, у которых эти значения меньше. Признак же «Страна» решено не кодировать через `One-Hot Encoding` [11], поскольку это привело бы к появлению сотен дополнительных столбцов и неоправданной нагрузке на память.

3.2. Обучение и оценка модели.

Чтобы обрабатывать данные аккуратно и не допустить утечки данных (data leakage), мы применили `Pipeline`. Утечка данных — одна из самых

коварных проблем в машинном обучении. Она возникает, когда информация из тестовой выборки или из будущих наблюдений случайно используется при обучении модели. Из-за этого оценки качества на валидации становятся неоправданно оптимистичными, а модель на практике оказывается совершенно непригодной.

Затем мы поместили этот Pipeline в ColumnTransformer. Это позволяет применять разные преобразования к разным группам столбцов: к числовым признакам — StandardScaler, к категориальному признаку «Страна» — TargetEncoder [12]. Полученный ColumnTransformer мы передали в итоговый Pipeline вместе с самой моделью (Random Forest). Благодаря такой архитектуре вся предобработка и обучение происходят внутри объекта Pipeline. Он автоматически гарантирует, что на каждом фолде кросс-валидации все преобразования (включая вычисление средних для Target Encoding) выполняются только на обучающей части фолда, а затем применяются к валидационной части — без какой-либо утечки [10].

```
num = x.drop('country',axis=1).columns.tolist()

preprocessor = ColumnTransformer(transformers=[

    ('num_features',StandardScaler(),num),

    ('country',TargetEncoder(smoothing=10),['country'])])

model = Pipeline(steps=[('preprocessor', preprocessor),
```

```
('regressor', RandomForestRegressor(random_state=42))])
```

После сборки пайплайна мы повторили кросс-валидацию с теми же параметрами ($cv=6$), чтобы оценить, насколько улучшилась стабильность модели и уменьшился ли разброс значений RMSE между фолдами по сравнению с базовой версией без предобработки и без учёта странового признака.

Результаты кросс-валидации модели с предобработкой данных (StandardScaler и Target Encoding):

RMSE: [22,75 млрд; 1,78 млрд; 5,08 млрд; 5,09 млрд; 6,52 млрд; 5,56 млрд] (в долларах).

Эти результаты почти не отличаются от тех, что дала базовая модель Random Forest из второй главы. Среднее значение RMSE по шести фолдам получилось около 7,7 млрд долларов — примерно столько же, сколько у базовой модели (7,6 млрд). Характер разброса ошибок тоже сохранился: пять фолдов показывают стабильные значения от 1,8 до 6,5 млрд долларов, а один фолд по-прежнему даёт сильно завышенную ошибку — 22,75 млрд долларов. Это говорит о том, что проблема нестабильности, обнаруженная раньше, никуда не исчезла.

3.3. Сравнительный анализ результатов до и после предобработки.

Таблица 3: Результаты оценки модели после предобработки

Метрика	Значение
R^2	0.993
MAE	6119185947.44
MSE	9.231197938496993e+20
RMSE	30382886529.25

Показатели на тестовой выборке тоже не показали заметных улучшений: $R^2 = 0,993$, MAE = 6,12 млрд долларов, RMSE = 30,4 млрд долларов. Все эти значения почти в точности совпадают с результатами базовой модели ($R^2 = 0,993$, MAE = 6,14 млрд, RMSE = 30,3 млрд).

Значит, стандартизация признаков и добавление категориальной переменной «страна» через Target Encoding не привели к сколько-нибудь значимому повышению качества прогнозов. Объясняется это тем, что случайный лес, как ансамблевый метод на основе решающих деревьев, изначально устойчив к разному масштабу признаков и сам способен выявлять сложные нелинейные зависимости, в том числе связанные с особенностями стран, даже без явного кодирования переменной «страна». По сути, модель и без

этих доработок уже достигала практически максимального качества на исторических данных.

Выводы: Основная причина заключается в самом алгоритме, который мы используем, — случайном лесе (Random Forest). Как уже отмечалось ранее, деревья решений, лежащие в основе случайного леса, принимают решения на основе пороговых значений отдельных признаков и не зависят от линейных преобразований масштаба, таких как стандартизация. Изменение масштаба числовых признаков с помощью StandardScaler никак не влияет на способность дерева находить оптимальные точки разделения — достаточно просто скорректировать пороговые значения. Поэтому стандартизация, столь важная для линейных моделей (логистическая регрессия, SVM, метод главных компонент), оказалась практически бесполезной для случайного леса. Аналогично, добавление признака «Страна» через Target Encoding не улучшило результат, вероятно, потому что другие признаки уже содержали всю необходимую информацию об экономических особенностях каждой страны. Включая такие переменные, как объём экспорта, численность населения, уровень грамотности, инвестиции и т.д., модель уже способна косвенно идентифицировать «богатые» и «бедные» страны без явного указания их названия. Target Encoding мог бы помочь в случае сильной нелинейности или страновых эффектов, не объяснимых другими признаками, однако в нашем наборе данных, по-видимому, такие уникальные эффекты отсутствуют либо их влияние слишком мало на фоне остальных факторов. Более того, добавление закодированного признака страны при ограниченном объеме данных могло даже привести к легкому переобучению, хотя кросс-валидация и показала, что катастрофического ухудшения не произошло.

Следует также признать, что базовая модель случайного леса с параметрами по умолчанию изначально показала очень высокое качество ($R^2 = 0,993$). Это означает, что практически вся дисперсия целевой переменной уже объясняется исходными признаками без какой-либо специальной обработки. Улучшить R^2 с 0,993 до 0,995 или 0,999 физически возможно, но такая разница вряд ли будет иметь практическое значение, особенно с учётом того, что ошибка RMSE порядка 30 млрд долларов остаётся на том же уровне. Проще говоря, модели уже нечему учиться сверх того, что она уже выучила, — информационная ёмкость признаков исчерпана. Тем не менее, проведённая работа не была напрасной: мы убедились в робастности случайного леса к масштабированию, получили отрицательный, но важный вывод о ненужности кодирования страны в данном контексте, а главное — построили корректный пайплайн с защитой от утечки данных, который можно использовать для будущих экспериментов.

Заключение

В рамках этой курсовой работы строилась модель машинного обучения, призванная прогнозировать валовой внутренний продукт (ВВП) на основе панельных данных по 200 странам за период с 1970 по 2021 год. В ход пошёл алгоритм «случайный лес» — такой метод уже успел хорошо себя показать в задачах с обилием признаков.

Первая глава посвящена статистическому анализу данных. Полученные результаты обнажили сильную правостороннюю асимметрию, что объясняется огромным разрывом между развитыми и развивающимися государствами. Корреляционный анализ, в свою очередь, выявил серьёзную мультиколлинеарность между показателями, но для ансамблевых методов эта проблема не столь страшна.

Во второй главе строилась базовая модель случайного леса с параметрами, выставленными по умолчанию. Обучение проводилось на данных за 1970–2011 годы, а тестирование — на периоде 2012–2021 годов. Подобный подход позволил сформулировать задачу именно как прогнозирование ВВП, а не простое подгон под историю. Результаты базовой модели оказались впечатляющими: коэффициент детерминации достиг 0,993, то есть модель объясняет более 99% дисперсии ВВП на тестовом промежутке. Однако обнаруженная разница в показателях всё же намекает на чувствительность модели к тому, какие именно страны и годы попали в обучающую выборку.

В третьей главе была предпринята попытка доработать модель за счёт стандартизации признаков и добавления категориальной переменной «страна».

Итоговые цифры вышли следующими: $R^2 = 0,993$, $RMSE = 30,4$ млрд долларов. Из этого удалось сделать важный вывод: случайный лес в силу своей древовидной природы попросту не нуждается в масштабировании признаков. Деревья решений принимают решения на основе пороговых значений, поэтому стандартизация здесь практически не влияет на качество — масштаб признаков для таких алгоритмов не играет решающей роли.

Таким образом, базовая модель случайного леса без какой-либо дополнительной предобработки данных оказалась самым простым и в то же время наиболее действенным решением для прогнозирования ВВП в рамках этой работы. Стоит особо подчеркнуть: любые дальнейшие попытки улучшить результат имеет смысл связывать не с предобработкой, а с совершенно иными аспектами моделирования. Взгляд в будущее позволяет наметить как минимум два направления. Первое — использование альтернативных методов ансамблирования, таких как градиентный бустинг, XGBoost, LightGBM или CatBoost: эти алгоритмы порой демонстрируют более высокую устойчивость на панельных данных. Второе — учёт временной структуры данных через специализированные модели рядов динамики, например ARIMA, LSTM или Prophet, чтобы прогнозировать ВВП не только за счёт межстрановых различий, но и в чистом временном разрезе; (3) расширение набора предикторов за счёт институциональных и политических факторов (индекс восприятия коррупции, уровень демократии, качество регулирования), которых не было в исходном наборе данных; (4) использование методов удаления выбросов или взвешенной кросс-валидации, чтобы уменьшить влияние стран с экстремальными значениями ВВП на стабильность модели. Тем не менее, уже достигнутое качество ($R^2 = 0,993$) позволяет считать модель пригодной для практического

использования в целях макроэкономического анализа и прогнозирования, особенно в контексте долгосрочных межстрановых сравнений.

Список литературы

1. Breiman L. Bagging predictors // Machine Learning. – 1996a. – Vol. 26, № 2. – P. 123–140.
2. Breiman L. Using adaptive bagging to debias regressions // Technical Report 547, Statistics Dept. UCB. – 1999.
3. Arlot S., Celisse A. A survey of cross-validation procedures for model selection // Statistics Surveys. – 2010. – Vol. 4. – P. 40–79.
4. Arlot S., Lerasle M. Choice of V for V-fold cross-validation in least-squares density estimation // Journal of Machine Learning Research. – 2016.
5. Breiman L. Machine Learning. – 2001. – Vol. 45. – P. 5–32.
6. Breiman L., Spector P. Submodel Selection and Evaluation in Regression. The X-Random Case // International Statistical Review / Revue Internationale de Statistique. – 1992. – Vol. 60. – P. 291.
7. Bürkner P.-C., Gabry J., Vehtari A. Approximate leave-future-out cross-validation for Bayesian time series models // Journal of Statistical Computation and Simulation. – 2020. – Vol. 90. – P. 2499–2523.
8. Cawley G. C., Talbot N. L. On over-fitting in model selection and subsequent selection bias in performance evaluation // Journal of Machine Learning Research. – 2010. – Vol. 11. – P. 2079–2107.
9. Davison A. C., Hinkley D. V. Bootstrap methods and their application. – Cambridge University Press, 1997.
10. Claeskens G., Hjort N. L. Model Selection and Model Averaging. – Cambridge Series in Statistical and Probabilistic Mathematics, Cambridge University Press, 2008.
11. Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32.

12. James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning: with Applications in R* (2nd ed.). Springer.
13. Micci-Barreca, D. (2001). A preprocessing scheme for high-cardinality categorical attributes in classification and prediction problems. *ACM SIGKDD Explorations Newsletter*, 3(1), 27–32.
14. Wickham, H., & Grolemund, G. (2017). *R for Data Science*. O'Reilly.
15. Buitinck, L., et al. (2013). API design for machine learning software: experiences from the scikit-learn project. *ECML PKDD Workshop: Languages for Data Mining and Machine Learning*.
16. Kaufman, S., Rosset, S., & Perlich, C. (2011). Leakage in data mining: Formulation, detection, and avoidance. *Proceedings of the 17th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*.
17. Arlot, S., & Celisse, A. (2010). A survey of cross-validation procedures for model selection. *Statistics Surveys*, 4, 40–79.

Приложение

```
import pandas as pd

import numpy as np

import matplotlib.pyplot as plt

import seaborn as sns


df= pd.read_csv('Global-Economy-Indicators.csv')

standard_columns = df.columns.str.strip().str.lower().str.replace(' ',
'_').str.replace(',','')

new_columns = dict(zip(df.columns, standard_columns))

df.rename(columns=new_columns, inplace=True)

df.interpolate(inplace=True)

#2

original_options = pd.get_option('display.float_format')

pd.set_option('display.float_format', '{:.0f}'.format)

display(df.iloc[:, 3:].describe())

pd.set_option('display.float_format', original_options)

cv = df.iloc[:,3:].std() / df.iloc[:,3:].mean() * 100

print('Коэффициент вариации:\n')

display(cv)

#3

fig,ax = plt.subplots(2,3, figsize=(15,8))

ax[0,0].hist(df['construction'],bins=50,log=True)

ax[0,1].hist(df['manufacturing'],bins=50,log=True)

ax[0,2].hist(df['mining_manufacturing_utilities'],bins=50,log=True)

ax[1,0].hist(df['transport_storage_and_communication'],bins=50,log=True)

ax[1,1].hist(df['other_activities'],bins=50,log=True)
```

```

ax[0,0].set_title('Construction')

ax[0,1].set_title('manufacturing')

ax[0,2].set_title('mining_manufacturing_utilities')

ax[1,0].set_title('transport_storage_and_communication')

ax[1,1].set_title('other_activities')


fig,ax = plt.subplots(2,3, figsize=(15,8))

ax[0,0].hist(df['exports_of_goods_and_services'],bins=50,log=True)

ax[0,1].hist(df['imports_of_goods_and_services'],bins=50,log=True)

ax[0,2].hist(df['final_consumption_expenditure'],bins=50,log=True)

ax[1,0].hist(df['gross_national_income(gni)_in_usd'],bins=50,log=True)

ax[1,1].hist(df['population'],bins=50,log =True)

ax[1,2].hist(df['gross_domestic_product_(gdp)'],bins=50,log=True,color='red')


ax[0,0].set_title('exports')

ax[0,1].set_title('imports')

ax[0,2].set_title('final_consumption_expenditure')

ax[1,0].set_title('gross_national_income')

ax[1,1].set_title('population')

ax[1,2].set_title('GDP')


# 4.

cor= df.iloc[:,3:].corr()

plt.figure(figsize=(12,8))

sns.heatmap(cor,

            annot=True,

```

```

        fmt=".2f",

        cmap='coolwarm',

        center=0,

        square=True,

        linewidths=0.5,

        vmin=-1,

        vmax=1)

plt.xticks(rotation=45, ha='right')

plt.title('Матрица корреляции', fontsize=16)

plt.tight_layout()

plt.show()

```

```

from sklearn.model_selection import
train_test_split,GridSearchCV,cross_val_score

from sklearn.ensemble import RandomForestRegressor

from sklearn.metrics import
mean_squared_error,mean_absolute_error,r2_score,root_mean_squared_error

x= df.drop(['gross_domestic_product_(gdp)','country'],axis =1)

y= df['gross_domestic_product_(gdp)']

x_train = x[df['year'] <= 2011]

x_test  = x[df['year'] > 2011]

y_train = y[df['year'] <= 2011]

y_test  = y[df['year'] > 2011]

model =RandomForestRegressor(random_state=42)

model.fit(x_train, y_train)

cv = cross_val_score(model,x_train,y_train,

```

```

        scoring='neg_mean_squared_error',cv= 6)

cv_rmse = np.sqrt(-cv)

print(f"RMSE fold: {cv_rmse}")


y_pred= model.predict(x_test)

print('r2',r2_score(y_test,y_pred))

print('MAE',mean_absolute_error(y_test,y_pred))

print('MSE',mean_squared_error(y_test,y_pred))

print('RMSE',root_mean_squared_error(y_test,y_pred))

```

```

from sklearn.model_selection import cross_val_score

from sklearn.preprocessing import StandardScaler

from category_encoders import TargetEncoder

from sklearn.pipeline import Pipeline

from sklearn.compose import ColumnTransformer

from sklearn.ensemble import RandomForestRegressor

from sklearn.metrics import
mean_squared_error,mean_absolute_error,r2_score,root_mean_squared_error


x= df.drop('gross_domestic_product_(gdp)',axis =1)

y= df['gross_domestic_product_(gdp)']

x_train = x[df['year'] <= 2011]

x_test  = x[df['year'] > 2011]

y_train = y[df['year'] <= 2011]

y_test  = y[df['year'] > 2011]

num = x.drop('country',axis=1).columns.tolist()

preprocessor = ColumnTransformer(transformers=[

```

```

        ('num_features', StandardScaler(), num),

        ('country', TargetEncoder(smoothing=10), ['country']))

    ])

model = Pipeline(steps=[('preprocessor', preprocessor),
                        ('regressor', RandomForestRegressor(random_state=42))])

model.fit(x_train, y_train)

cv =
cross_val_score(model, x_train, y_train, scoring='neg_mean_squared_error', cv=
6)

cv_rmse = np.sqrt(-cv)

print(f"RMSE từng fold: {cv_rmse}")

y_pred= model.predict(x_test)

print('r2', r2_score(y_test, y_pred))

print('MAE', mean_absolute_error(y_test, y_pred))

print('MSE', mean_squared_error(y_test, y_pred))

print('RMSE', root_mean_squared_error(y_test, y_pred))

```